Modelagem dos Dados de Entrada

Simulação Discreta

Filipe Saraiva

Conteúdo

Introdução

Coleta de Dados

Tratamento dos Dados
- Outlier
- Análise de Correlação

Inferência
- Histograma
- Teste de Aderência

Conclusões

Conteúdo

Introdução

Coleta de Dados

Tratamento dos Dados
- Outlier
- Análise de Correlação

Inferência
- Histograma
- Teste de Aderência

Conclusões

Introdução

Nessa aula serão discutidas as maneiras pelas quais dados de entrada em um projeto de simulação discreta são obtidos e pré-tratados.

Também serão apresentadas aplicações muito diretas dos conceitos de Estatística Descritiva vistos anteriormente.

Introdução

No geral, o procedimento de modelagem dos dados compreende três fases:

- Coleta de dados;
- Tratamento dos dados;
- Inferência

Essas 3 etapas serão discutidas nessa apresentação.

Conteúdo

Introdução

Coleta de Dados

Tratamento dos Dados
- Outlier
- Análise de Correlação

Inferência
- Histograma
- Teste de Aderência

Conclusões

Coleta de Dados

A coleta de dados para simulação discreta se inicia com a escolha das variáveis de entrada do sistema a ser simulado.

É importante ter muito clara a diferença entre **dados de entrada** e **dados de saída** – o que se pretende obter – da simulação.

Coleta de Dados

A maioria dos sistemas que procuramos modelar possui algum fenônemo aleatório que o governa. Exemplos:

- Tempo de operação em uma máquina - repetindo a mesma operação, mas levando tempos diferentes para processá-la;
- Filas de banco - clientes chegam em horários e quantidades diferentes;
- Reposição de refil de bebidas em bares - tempo que o consumidor leva para consumir uma bebida varia de maneira aleatória.

Apesar da natureza aleatória dessas variáveis, é possível prever seu comportamento probabilístico a partir da observação em tempos anteriores.

Coleta de Dados

Exemplo

Um gerente de um supermercado quer estudar o tamanho da fila nos caixas de supermercado. Quais variáveis deverão ser analisadas?

- Número de prateleiras no supermercado
- Os tempos de atendimento nos caixas
- O número de clientes em fila
- O tempo de permanência dos clientes no supermercado
- O tempo de chegada sucessiva dos clientes nos caixas

Coleta de Dados

Exemplo

Um gerente de um supermercado quer estudar o tamanho da fila nos caixas de supermercado. Quais variáveis deverão ser analisadas?

- Número de prateleiras no supermercado
- **Os tempos de atendimento nos caixas**
- O número de clientes em fila – **Essa medida é resultado!**
- O tempo de permanência dos clientes no supermercado
- **O tempo de chegada sucessiva dos clientes nos caixas**

Coleta de Dados

Definidas as variáveis de entrada, cabe agora ao pesquisador mensurar um número considerável desses valores com a finalidade de criar uma amostra representativa do sistema.

Em que pese essas variáveis serem aleatórias, uma medição correta e precisa de uma amostra será suficiente para encontrarmos um modelo probabilístico que rege o fenômeno.

Coleta de Dados

O trabalho de medição dos dados é um trabalho de campo:

- Ir ao local e, utilizando um cronômetro, medir o tempo em que o fenômeno acontece, anotar o valor obtido quando o fenômeno finaliza, zerar o cronômetro, fazer nova medição do fenômeno, etc.
- O tamanho das observações deve ser entre 100 e 200 amostras. Menor que 100 pode comprometer a observação do fenômeno probabilístico, enquanto maior que 200 não traz ganho significativo.
- Coletar e anotar as observações na ordem, para permitir análise de correlação.
- Deve-se ter clareza se o fenômeno varia conforme o dia, horário ou outra variável relacionada com o momento em que foi colhido. Estudos devem levar essa característica em conta.

Coleta de Dados

Para o estudo da entrada de dados, supomos a medição dos clientes que chegam ao supermercado durante um determinado horário. A tabela abaixo apresenta as medições, em segundos, dessa entrada, compondo uma amostra de 200 observações.

11	5	2	0	9	9	1	5	1	3
3	3	7	4	12	8	5	2	6	1
11	1	2	4	2	1	3	9	0	10
3	3	1	5	18	4	22	8	3	0
8	9	2	3	12	1	3	1	7	5
14	7	7	28	1	3	2	11	13	2
0	1	6	12	15	0	6	7	19	1
1	9	1	5	3	17	10	15	43	2
6	1	13	13	19	10	9	20	19	2
27	5	20	5	10	8	2	3	1	1
4	3	6	13	10	9	1	1	3	9
9	4	0	3	6	3	27	3	18	4
6	0	2	2	8	4	5	1	4	18
1	0	16	20	2	2	2	12	28	0
7	3	18	12	3	2	8	3	19	12
5	4	6	0	5	0	3	7	0	8
8	12	3	7	1	3	1	3	2	5
4	9	4	12	4	11	9	2	0	5
8	24	1	5	12	9	17	728	12	6
4	3	5	7	4	4	4	11	3	8

Coleta de Dados

Com os dados medidos, finaliza-se a etapa de coleta dos mesmos e passa-se então para o tratamento desses dados.

Conteúdo

Introdução

Coleta de Dados

Tratamento dos Dados
- Outlier
- Análise de Correlação

Inferência
- Histograma
- Teste de Aderência

Conclusões

Tratamento dos Dados

Nessa etapa iniciam-se um conjunto de análises para explorar o conjunto de dados e então compreender o fenômeno probabilístico expresso neles.

Tratamento dos Dados

Utilizando Estatística Descritiva, obtem-se as seguintes medições para o conjunto de dados:

Medidas de Centralidade	
Média	10,43
Mediana	5
Moda	3
Mínimo	0
Máximo	728
Medidas de Dispersão	
Amplitude	728
Desvio Padrão	51,41
Variância	2.643,81
Coeficiente de Variação	492,74%
Coeficiente de Assimetria	0,144

Tratamento dos Dados

Na análise, descobrimos que o mínimo é 0 (diferentes clientes entrando juntos) e o máximo é 728 (ou seja, mais de 12 minutos!). A média é 10,44 segundos.

Essa primeira avaliação permite verificar o quão discrepante alguns dados se encontram. No caso, aquele 728 é uma medida que deve permanecer no conjunto de dados ou ser removida?

Os dados discrepantes são chamados de *outliers* e merecem uma avaliação detida sobre o que fazer com eles.

Tratamento dos Dados

Antes de discutirmos *outliers*, vale a pena entender o impacto dele nas medições do conjunto de dados.

Abaixo temos algumas medições com e sem o valor 728 do conjunto:

	Com *outlier*	**Sem *outlier***
Média	10,43	6,829
Mediana	5	5
Máximo	728	43
Amplitude	728	43
Desvio Padrão	51,41	6,60
Variância	2.643,81	43,59
Coeficiente de Variação	492,74%	96,68%

Conteúdo

Introdução

Coleta de Dados

Tratamento dos Dados
- Outlier
- Análise de Correlação

Inferência
- Histograma
- Teste de Aderência

Conclusões

Outlier

Dados não usuais em conjuntos de dados são chamados *outliers*.

As razões mais comuns para o seu surgimento são erro na coleta de dados ou a ocorrência de um evento raro e inesperado.

Outlier

Razões para o surgimento de *outliers*:

- Erro na coleta de dados – falha em sensor que realiza coleta, mas também ocorre quando feita de maneira manual. Erro na atualização da tabela de dados, e outras. No geral, quando esse é o motivo do *outlier*, devemos remover a observação.
- Eventos raros – um *outlier* difícil de se lidar pois situações atípicas podem ocorrer durante as medições.

Em todo caso, a avaliação se o *outlier* deve ou não ser removido da base de dados é uma decisão importante que deve levar em conta o bom senso e honestidade sobre o fenômeno em estudo.

Outlier

Existem algumas técnicas que permitem uma avaliação se determinado dado é um *outlier* a ser removido ou não.

Fazendo Q_1 e Q_3 os respectivos quartis 1 e 3, temos o cálculo da **Amplitude Interquartil** (A) dada por:

$$A = Q_3 - Q_1$$

Outlier

A partir da Amplitude Interquartil, temos os seguintes conjuntos de valores discrepantes:

Outlier moderado	valor $< Q_1 - 1{,}5A$	valor $> Q_3 + 1{,}5A$
Outlier extremo	valor $< Q_1 - 3A$	valor $> Q_3 + 3A$

Outlier

Para o exemplo, tem-se:

- $Q_1 = 2$
- $Q_3 = 9$
- $A = Q_3 - Q_1 = 7$ (Amplitude Interquartil)

Assim, os valores discrepantes serão:

Outlier moderado	valor < -8,5	valor > 19,5
Outlier extremo	valor < -19	valor > 30

Outlier

Para o exemplo, teremos 11 valores como *outliers* moderados e 2 como *outliers* extremos (43 e 728).

Em nossa avaliação, apenas o valor 728 deveria ser removido, visto que ele difere em grande medida dos demais.

Entretanto, cabe o comentário: é importante avaliar bem se o *outlier* deve ser removido ou não.

Conteúdo

Introdução

Coleta de Dados

Tratamento dos Dados
- Outlier
- Análise de Correlação

Inferência
- Histograma
- Teste de Aderência

Conclusões

Análise de Correlação

Removido os *outliers*, é necessário ainda fazer uma avaliação se o conjunto de dados contém valores independentes ou não.

Essa situação em geral não é válida quando os dados apresentam uma “curva de aprendizado”. Nesses casos, significa que a obtenção dos dados foi realizada em alguma situação onde o operador foi “aprendendo” a tarefa ao longo do tempo, não demonstrando o tempo real de execução da tarefa.

Análise de Correlação

Para fazer essa análise, basta criar um gráfico de dispersão com o conjunto de dados, na ordem em que foram auferidos, e verificar se ele está com os pontos bem dispersos ou se há alguma aparência de "evolução" neles.

Sendo as observações os valores expressos por x_1, x_2, x_3, x_4, ..., $x_{(n-1)}$, x_n, o gráfico a ser criado deve ser feita pelos pares (x_1, x_2), (x_3, x_4), ..., ($x_{(n-1)}$, x_n).

Análise de Correlação

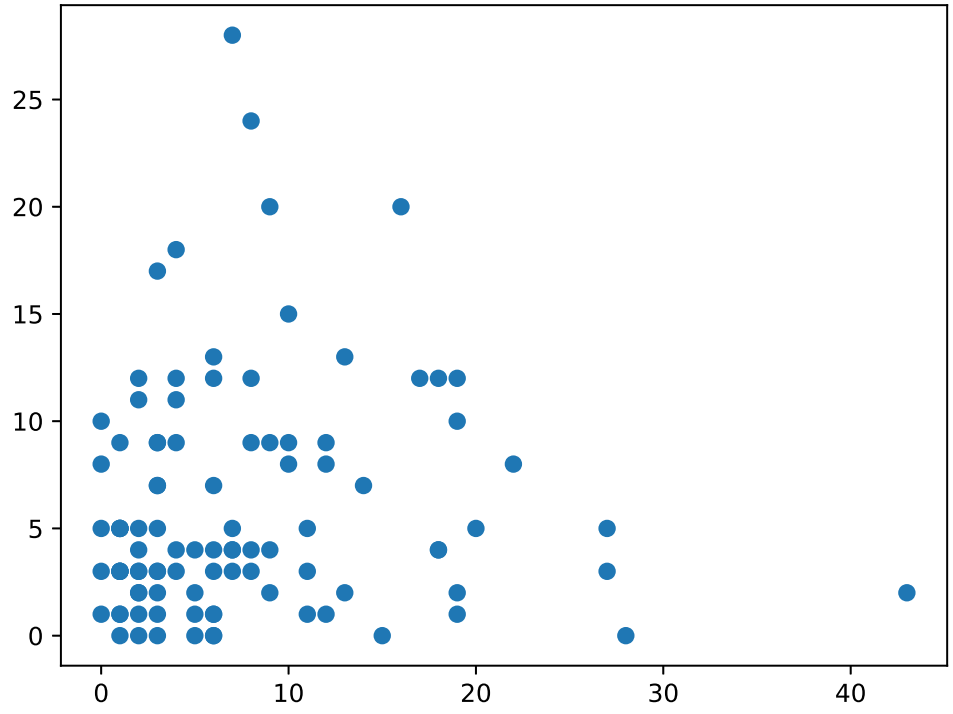

Acima temos o gráfico de dispersão para o conjunto de dados que trabalhamos no exemplo. Ele não aparenta ter alguma evolução.

Análise de Correlação

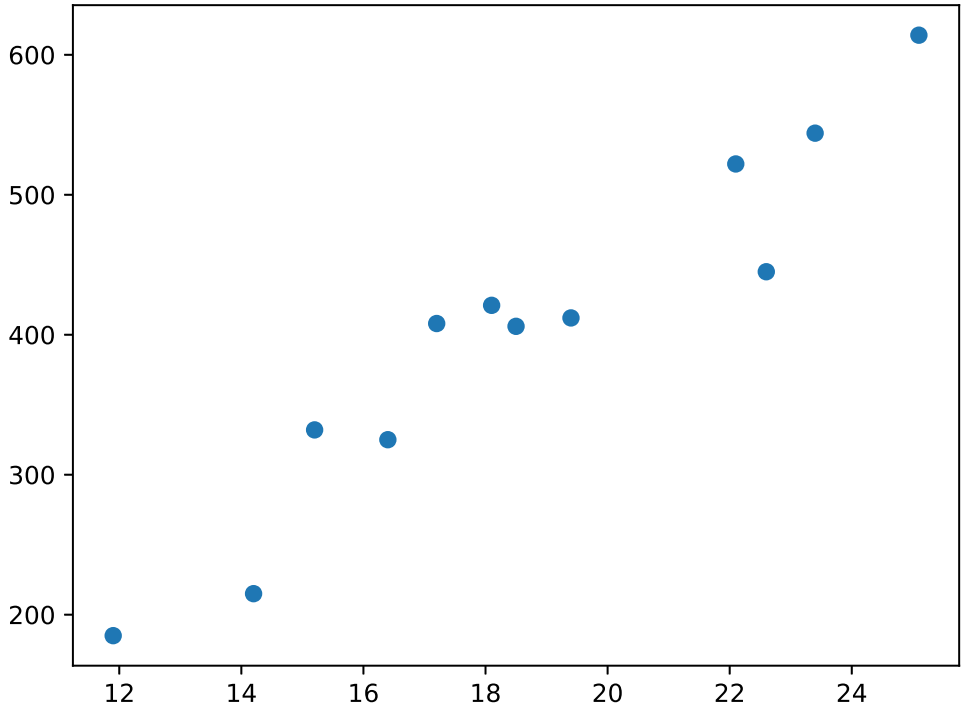

No exemplo acima temos um gráfico que apresenta um tipo de "evolução", que seria a curva de aprendizado.

Análise de Correlação

Em Python, podemos utilizar o pacote **matplotlib.pyplot** para gerar esse gráfico:

```
import matplotlib.pyplot as plt
# sendo x e y as listas com as abscissas e ordenadas do gráfico
plt.plot(x, y, 'o')
plt.show()
```

Conteúdo

Introdução

Coleta de Dados

Tratamento dos Dados
- Outlier
- Análise de Correlação

Inferência
- Histograma
- Teste de Aderência

Conclusões

Inferência

Parte-se agora para a última etapa do pré-processamento dos dados, a Inferência.

Nessa etapa, tenta-se encontrar o modelo probabilístico que mais se adequa aos dados mensurados, de forma que o comportamento das variáveis de entrada seja descoberto.

Conteúdo

Introdução

Coleta de Dados

Tratamento dos Dados
- Outlier
- Análise de Correlação

Inferência
- Histograma
- Teste de Aderência

Conclusões

Histograma

O primeiro passo da análise para inferência é criar um histograma do conjunto de dados.

Um histograma é um gráfico de frequência que mostra como uma população de dados está distribuída – ou seja, ele mostra quantas vezes temos repetido um determinado valor ou intervalo de valores no conjunto.

Histograma

Para iniciar a análise, precisamos calcular o número de classes a serem utilizadas no histograma. A fórmula para esse cálculo é dada por:

$$K = 1 + 3{,}3\log_{10} n$$

Onde:

- K – número de classes (portanto, deve ser arredondada para um inteiro)
- n – número de observações na amostra

Histograma

Para nosso exemplo, teremos:

$K = 1 + 3{,}3\log_{10} n$
$K = 1 + 3{,}3\log_{10} 199$
$K = 8{,}59 \approx 9$

Lembrando que como tiramos o *outlier*, agora temos 199 observações.

Histograma

Em Python utilizaremos a biblioteca **math** e a função padrão **round** para realizar esse cálculo da seguinte forma:

```
import math
round(1 + 3.3 * math.log10(199))
```

Histograma

Com o número de classes sendo igual a 9, procedemos para calcular o tamanho do passo para o intervalo de valores em classe. Para tanto, dividimos a amplitude pelo número de classes:

$$\mathrm{h} = \frac{A}{K}$$

Onde:

- h – tamanho de cada classe
- A – amplitude
- K – número de classes

Histograma

Para o exemplo fica:

$h = \frac{A}{K}$
$h = \frac{43}{9}$
$h = 4{,}8$

Ou seja, teremos portanto 9 classes com intervalos de valores com passos de 4,8 para cada.

Histograma

A tabela abaixo apresenta as classes, seus respectivos intervalos de valores, e a frequência de cada classe no conjunto de dados.

Classes	**Intervalos**	**Frequência**
1	valor $\leq$ 4,8	96
2	4,8 < valor $\leq$ 9,6	55
3	9,6 < valor $\leq$ 14,3	25
4	14,3 < valor $\leq$ 19,1	13
5	19,1 < valor $\leq$ 23,9	4
6	23,9 < valor $\leq$ 28,7	5
7	28,7 < valor $\leq$ 33,4	0
8	33,4 < valor $\leq$ 38,2	0
9	38,2 < valor	1

Histograma

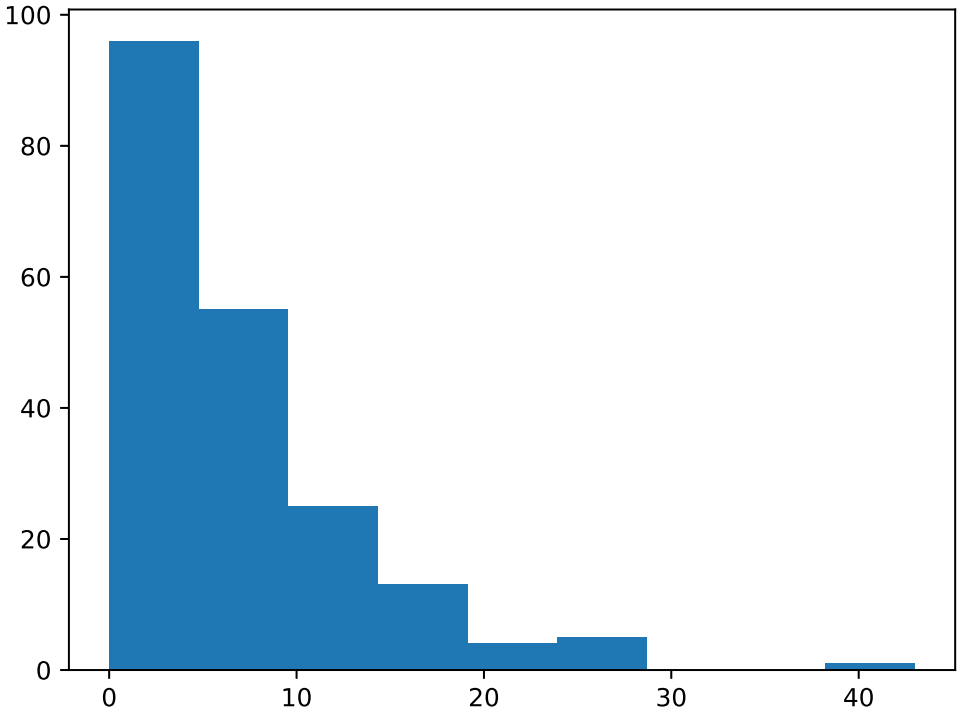

A figura acima apresenta o histograma para o conjunto de dados do exemplo trabalhado.

Histograma

A exemplo dos gráficos anteriores, também utilizaremos o **matplotlib.pyplot** para gerar o gráfico de histograma. Para tanto, precisamos além dos dados, calcular o número de classes e passá-lo como argumento na função.

```
import matplotlib.pyplot as plt
# sendo x o conjunto de dados e k o número de classes
plt.hist(x, bins=k)
plt.show()
```

Conteúdo

Introdução

Coleta de Dados

Tratamento dos Dados
- Outlier
- Análise de Correlação

Inferência
- Histograma
- Teste de Aderência

Conclusões

Teste de Aderência

Com o histograma criado, a dúvida que fica é: “será que os dados podem ser modelados a partir de alguma distribuição de probabilidades específica?”

Se isso for possível, o fenômeno modelado pode ser modelado utilizando essa função de probabilidade, e ela pode ser utilizada para gerar dados de entrada.

Para verificar se o fenômeno medido é compatível com alguma distribuição, fazemos os **Testes de Aderências**.

Teste de Aderência

Os testes de aderência nada mais são do que verificar se o histograma é similar a alguma função de probabilidade conhecida.

Há 2 maneiras de realizar essa verificação: a partir de uma análise "visual" do histograma e dos gráficos de distribuições, e a partir de métodos matemáticos para esse teste.

Teste de Aderência

Sobre o método gráfico, precisamos relembrar as principais funções de distribuição probabilidade utilizadas. Veremos as seguintes:

- Uniforme
- Exponencial
- Normal
- Lognormal
- Triangular

Nos slides a seguir, a **Função** significa a Função Densidade de Probabilidade de cada distribuição.

Teste de Aderência – Distribuição Uniforme

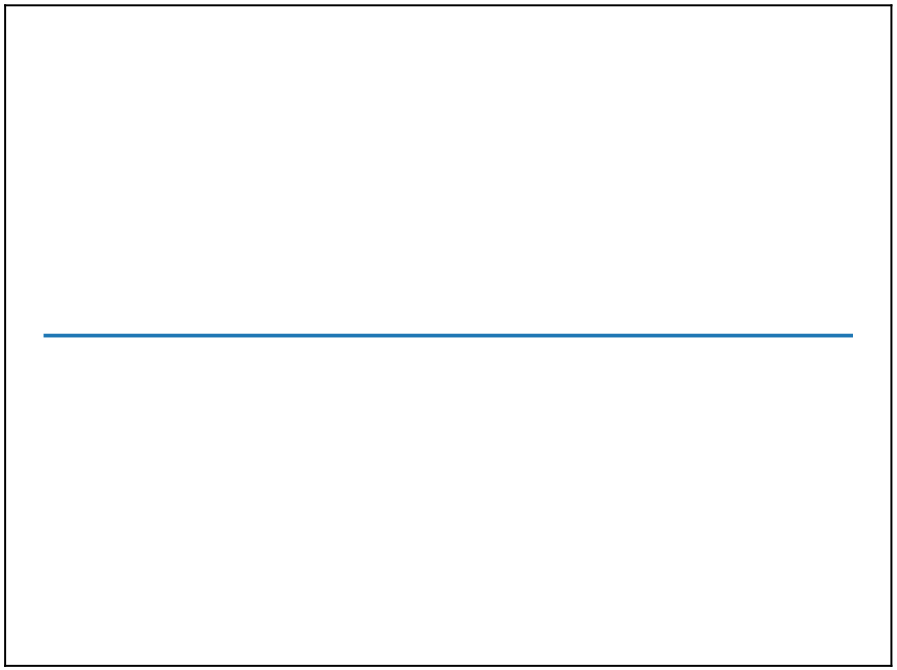

Parâmetros:
a - menor valor;
b - maior valor.

Função: $\frac{1}{b-a}$

Média: $\frac{a+b}{2}$

Variância: $\frac{(b-a)^2}{12}$

Teste de Aderência – Distribuição Exponencial

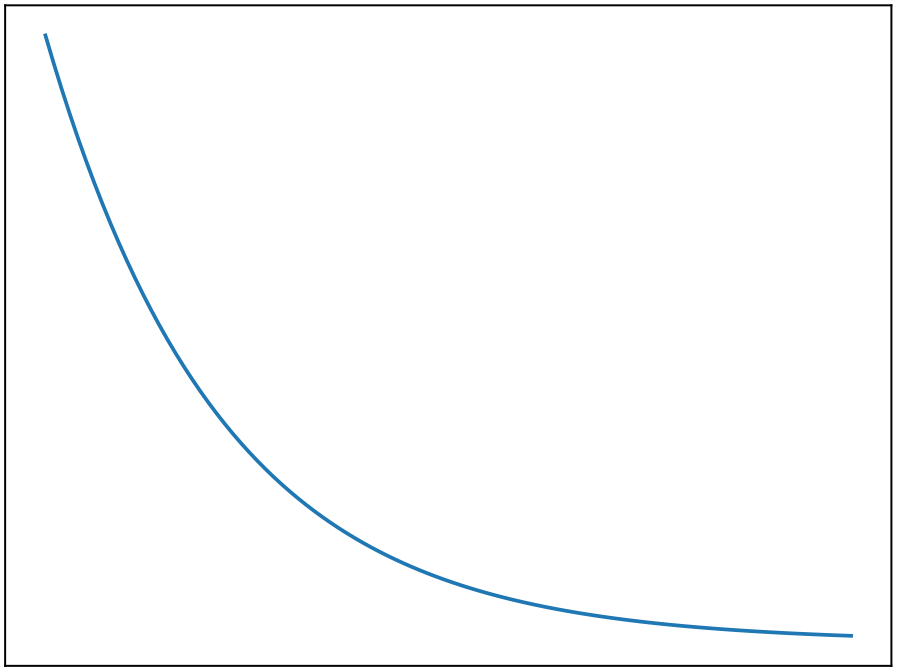

Parâmetros:
λ - taxa de ocorrências

Função: $\lambda e^{-\lambda x}$

Média: $\frac{1}{\lambda}$

Variância: $\frac{1}{\lambda^2}$

Teste de Aderência – Distribuição Normal

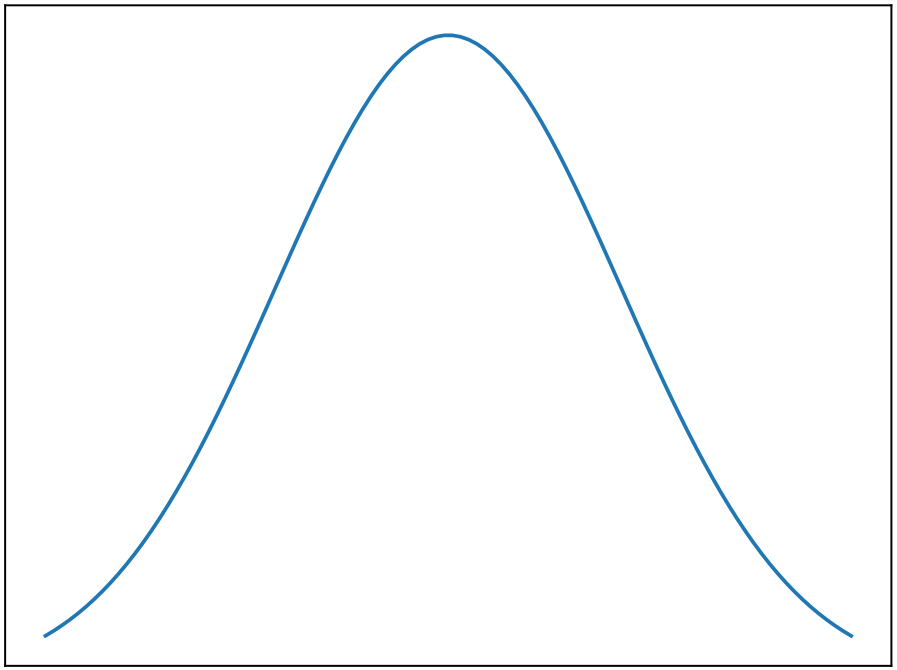

Parâmetros:
σ^2 - variância
μ - média

Função: $\frac{1}{\sigma\sqrt{2\pi}} e^{\frac{-(x-\mu)^2}{2\sigma^2}}$

Média: μ

Variância: σ^2

Teste de Aderência – Distribuição Lognormal

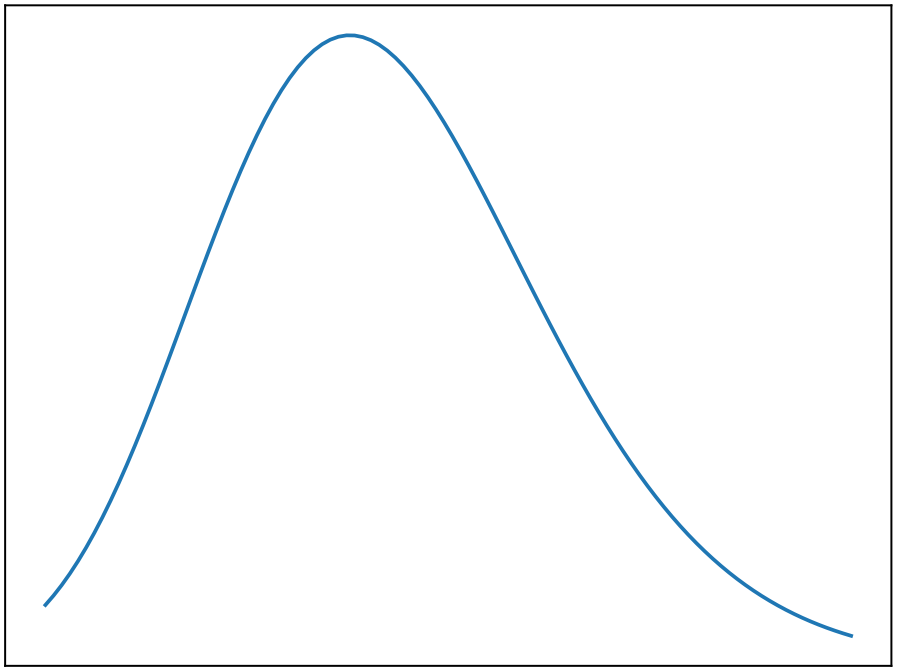

Parâmetros:

σ - forma ou dispersão

μ - escala ou posição

Função: $\frac{1}{\sqrt{2\pi}} e^{\frac{-(ln(x)-\mu)^2}{2\sigma^2}}$

Média: $e^{\mu+\frac{\sigma^2}{2}}$

Variância: $e^{2\mu+\sigma^2}(e^{\sigma^2})$

Teste de Aderência – Distribuição Triangular

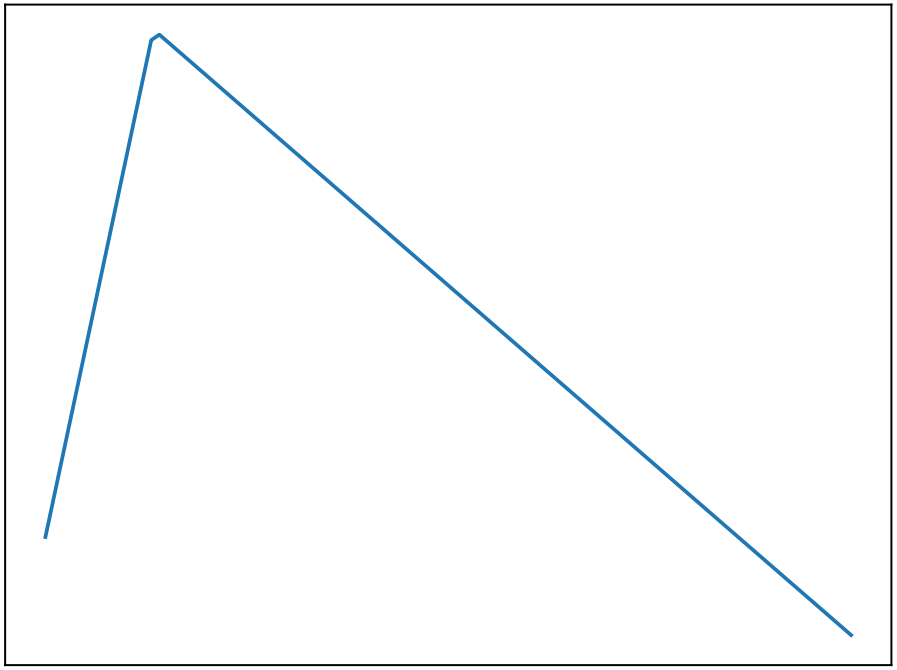

Parâmetros:

a - menor valor

b - maior valor

m - moda

Onde: $a < m < b$

Função:

$\frac{2(x-a)}{(m-a)(b-a)}$, para $a \leq x \leq m$

$\frac{2(b-x)}{(b-a)(b-a)}$, para $m \leq x \leq b$

Média:

$\frac{a+m+b}{3}$

Variância:

$\frac{a^2+m^2+b^2-ma-ab-mb}{18}$

Teste de Aderência

Conhecida as principais distribuições, o teste de aderência visual consistirá portanto de verificar visualmente qual delas consegue melhor representar o histograma obtido do fenômeno em medição.

Entretanto, é importante notar que esse tipo de abordagem é sujeito a falhas e nem sempre preciso.

Teste de Aderência

Para uma maior precisão no teste de aderência é recomendado aplicar algum método matemático/estatístico para a verificação.

A literatura traz alguns, e nessa aplicaremos um deles: o **Teste de Kolmogorov-Smirnov** (KS).

Esse teste consiste em observar a distância máxima entre a função acumulada das observações e a função acumulada de algum modelo teórico de uma distribuição.

Caso essa distância esteja acima de um limiar, pode-se considerar que a distribuição observada é aderente à distribuição teórica comparada.

Teste de Aderência

Para realizar o teste KS é necessário criar uma tabela com as seguintes colunas:

1. **Valor observado** – identificar quais são os valores presentes na base de dados e ordená-los em ordem crescente;
2. **Frequência observada** – contabilizar quantas vezes cada valor aparece na base de dados;
3. **Frequência acumulada observada** – somar as frequências observadas a cada linha, tanto do valor na linha quanto dos valores menores;
4. **Frequência acumulada observada normalizada** – divide-se a frequência acumulada observada pelo número total de dados;

Ao final dessa primeira parte teremos calculado a frequência de elementos observados na base e também a frequência normalizada.

Teste de Aderência

Utilizando o exemplo da aula, teríamos as seguintes primeiras linhas na tabela:

V.O.	F.O.	F.A.O.	F.A.O.N.
0	13	13	0.07
1	23	36	0.18
2	18	54	0.27
3	26	80	0.4
...	...	...	...

Teste de Aderência

No próximo passo, precisaremos adicionar 2 colunas:

- Uma coluna com a frequência acumulada esperada da distribuição teórica que iremos comparar com a frequência acumulada observada normalizada;
- Uma coluna com o módulo (valor absoluto) entre as frequências acumuladas e teóricas calculadas.

Para a primeira coluna, será necessário a utilização da fórmula matemática da distribuição teórica que iremos analisar.

Teste de Aderência

Para esse exemplo na tabela, decidiu-se comparar com a distribuição exponencial.

Para fazer o cálculo das frequências teóricas, é necessário conhecer a função acumulada da distribuição. Para a distribuição exponencial, essa função é dada por $1 - e^{-\lambda x}$, onde λ é o inverso da média da distribuição.

Calculando a média da distribuição (6,83) teremos $\lambda = 0,146$. Assim, a fórmula será $1 - e^{-0,146x}$.

Teste de Aderência

Esse passo pode ser mais simples utilizando um software de planilha ou linguagem de programação.

A tabela ficará assim (F.A.T.N. = Frequência Acumulada Teórica Normalizada):

V.O.	**F.O.**	**F.A.O.**	**F.A.O.N.**	**F.A.T.N.**
0	13	13	0.07	0
1	23	36	0.18	0.14
2	18	54	0.27	0.25
3	26	80	0.4	0.35
...	...	...	...	...

Teste de Aderência

Calculado o F.A.T.N., agora criaremos uma nova coluna com o módulo (valor absoluto) da diferença entre F.A.T.N. e F.A.O.N., que chamaremos **D**.

A tabela ficará conforme:

V.O.	**F.O.**	**F.A.O.**	**F.A.O.N.**	**F.A.T.N.**	**D**
0	13	13	0.07	0	0.07
1	23	36	0.18	0.14	0.04
2	18	54	0.27	0.25	0.02
3	26	80	0.4	0.35	0.05
...	...	...	...	...	...

Finalmente, para verificar o teste de aderência, utilizamos o maior valor de **D** e verificamos a tabela do KS para saber como calcular o valor D_{crtico} dado um nível de significância α.

Teste de Aderência

Na tabela do KS o valor a ser buscado é relacionado com o α e o número de observações. Fazendo α = 0.05 e lembrando que temos (n =) 199 observações, a tabela nos indicará que o valor D_{crtico} deve ser calculado a partir da fórmula $\frac{1{,}36}{\sqrt{n}}$.

Assim: $D_{crtico} = \frac{1{,}36}{\sqrt{199}} = 0,0964$.

Como esse valor é maior que o maior valor de **D**, então a distribuição é aderente ao conjunto de dados.

Teste de Aderência

Atenção

A Tabela do KS comentada no slide anterior está disponível como material complementar da aula.

Conteúdo

Introdução

Coleta de Dados

Tratamento dos Dados
- Outlier
- Análise de Correlação

Inferência
- Histograma
- Teste de Aderência

Conclusões

Conclusões

- Tratamento de dados em simulação discreta é essencial para realização das simulações;
- Os dados precisam ser medidos em campo ou coletados a partir de tabelas, e em seguida é necessário encontrar uma distribuição probabilística que modele de que maneira o fenômeno se comporta;
- Com os histogramas e o teste de aderência via KS, é possível verificar se determinados dados é condizente com alguma distribuição probabilística.

Modelagem dos Dados de Entrada

Simulação Discreta

Filipe Saraiva